Projet 7:Implémentez un modèle de scoring

Kaoutar El Mardi

jury: Daouda Thioye

Table of contents

01

Introduction

04

Feature Importance Globale et Locale Data Drift 02

Problématique Et jeu de Données

05

Pipeline de Déploiement Scoring Client via l'API sur le Cloud 03

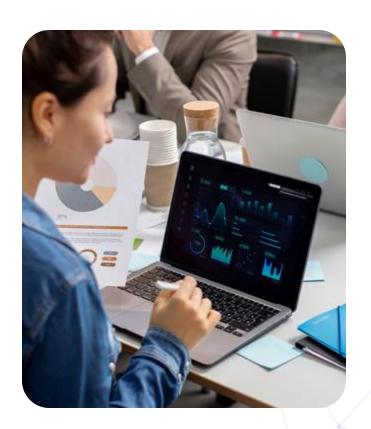
Modélisation et MLFlow UI

06

Conclusion

Introduction

"Prêt à dépenser", une société financière spécialisée dans les crédits à la consommation pour des personnes ayant peu ou pas du tout d'historique de prêt Cette présentation porte sur un projet de développement d'un outil de "scoring crédit" que nous avons réalisé pour notre entreprise.





Problématique



Jeu de données

```
data1 = pd.read_csv("application_train.csv")
data2=pd.read_csv("application_test.csv")
data3=pd.read_csv("bureau_balance.csv")
data4=pd.read_csv("bureau.csv")
data5=pd.read_csv("HomeCredit_columns_description.csv",encoding='ISO-8859-1')
data6=pd.read_csv("installments_payments.csv")
data7=pd.read_csv("PoS_CASH_balance.csv")
data8=pd.read_csv("previous_application.csv")
data9=pd.read_csv("sample submission.csv")
```

(356251, 797)

<class 'pandas.core.frame.DataFrame'>
Index: 356251 entries, 0 to 356254

Columns: 797 entries, SK_ID_CURR to CC_COUNT

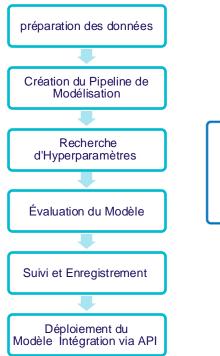
dtypes: bool(133), float64(606), int64(42), object(16)

memory usage: 1.8+ GB

\\\	
Identifiant unique pour chaque client dans le jeu de données.	SK_ID_CURR
Variable cible indiquant si le client a fait défaut sur le prêt (1 = défaut, 0 = non défaut).	TARGET
Code représentant le genre du client (0 = féminin, 1 = masculin, par exemple).	CODE_GENDER
Indicateur binaire indiquant si le client possède une voiture (1 = oui, 0 = non).	FLAG_OWN_CAR
Indicateur binaire indiquant si le client possède une propriété (1 = oui, 0 = non).	FLAG_OWN_REALTY
Nombre d'enfants à charge du client.	CNT_CHILDREN
Revenu total annuel du client.	AMT_INCOME_TOTAL
Montant total du crédit demandé par le client.	AMT_CREDIT
Montant annuel de l'annuité que le client doit payer pour le crédit.	AMT_ANNUITY
Type de contrat de prêt (Cash loans, Revolving loans).	NAME_CONTRACT_TYPE
Indicateur de possession de téléphone mobile.	FLAG_MOBIL
Indicateur si le client a un téléphone professionnel.	FLAG_EMP_PHONE
Indicateur si le client a un téléphone au travail.	FLAG_WORK_PHONE
Indicateur si le client a un mobile à contact permanent.	FLAG_CONT_MOBILE
Indicateur si le client a un téléphone fixe.	FLAG_PHONE
Indicateur si le client a un email.	FLAG_EMAIL
Type de profession du client.	OCCUPATION_TYPE
Nombre de membres dans la famille du client.	CNT_FAM_MEMBERS
Note de la région où vit le client.	REGION_RATING_CLIENT
Jour de la semaine où la demande de prêt a été initiée.	WEEKDAY_APPR_PROCESS_START
Heure de la journée où la demande de prêt a été initiée.	HOUR_APPR_PROCESS_START
Type d'organisation où le client travaille.	ORGANIZATION_TYPE
Score externe de la source 1.	EXT_SOURCE_1
Score externe de la source 2.	EXT_SOURCE_2
Score externe de la source 3.	EXT_SOURCE_3
Moyenne des valeurs pour les appartements associés au client.	APARTMENTS_AVG
Moyenne des valeurs pour les sous-sols associés au client.	BASEMENTAREA_AVG



Description du pipeline de modélisation

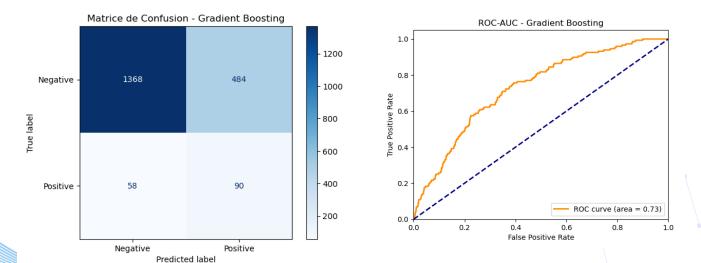


Machine Learning Workflow

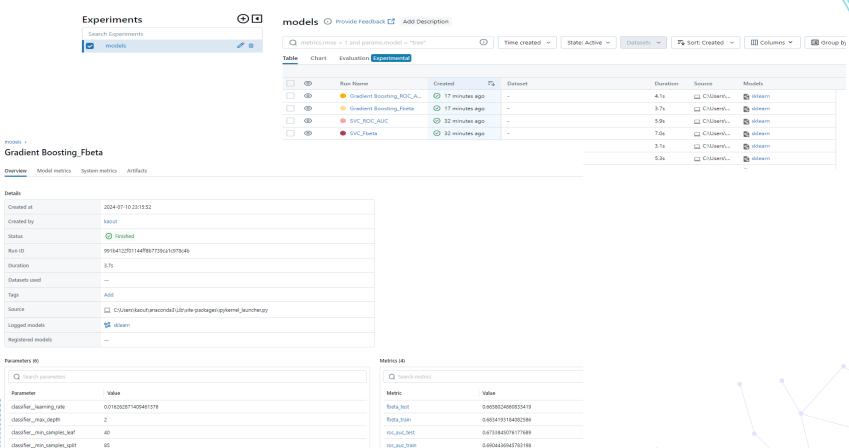


Algorithmes Resultats

	F-beta (train)	F-beta (test)	ROC AUC (train)	ROC AUC (test)	F-beta (cross- validation)	ROC AUC (cross- validation)	Model	Best Params	
0	0.676367	0.662848	0.685176	0.672596	0.674904	0.736434	Logistic Regression	{'classifierC': 1.230477933008369, 'classifi	
1	0.675421	0.661981	0.684216	0.671787	0.669426	0.734063	svc	{'classifier_kernel': 'linear', 'classifier	
2	0.683419	0.665802	0.690444	0.673385	0.659149	0.720698	Gradient Boosting	{'classifierlearning_rate': 0.01626287140946	



Visualisation du Tracking via MLFlow Ul



classifier n estimators

classifier subsample

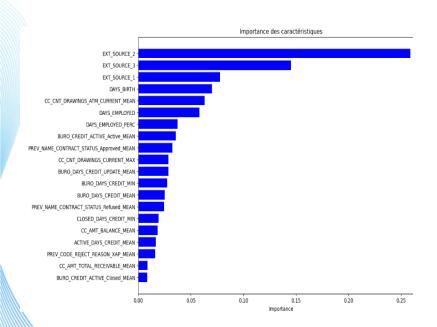
0.6861413832808716

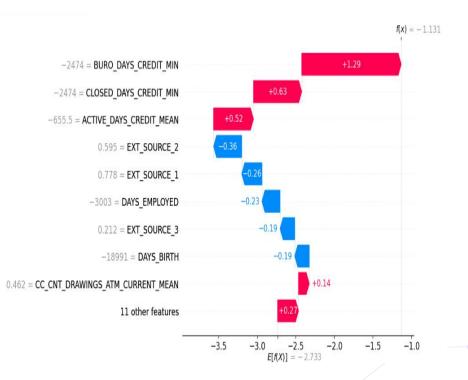


03

Feature Importance Globale et Locale Data Drift

Global et Local





Data drift

Dataset Drift

Dataset Drift is NOT detected. Dataset drift detection threshold is 0.5

121 Columns

9 Drifted Columns 0.0744

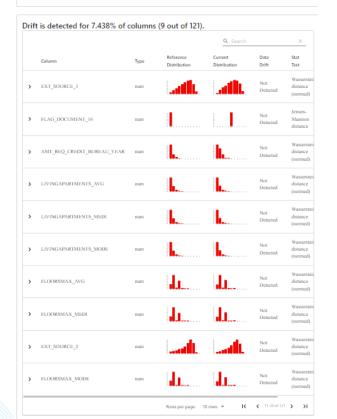
Share of Drifted Columns

Data Drift Summary

				Q Search	×	
	Column	Туре	Reference Distribution	Current Distribution	Data Drift	Stat Test
>	AMT_REQ_CREDIT_BUREAU_QRT	num	1	L	Detected	Wasserste distance (normed)
>	AMT_REQ_CREDIT_BUREAU_MON	num	L	1	Detected	Wasserste distance (normed)
>	AMT_GOODS_PRICE	num	L	L	Detected	Wasserste distance (normed)
>	AMT_CREDIT	num	L	1	Detected	Wasserste distance (normed)
>	AMT_ANNUITY	num	L	i.	Detected	Wasserste distance (normed)
>	AMT_REQ_CREDIT_BUREAU_WEEK	num	IL	1	Detected	Wasserste distance (normed)
>	NAME_CONTRACT_TYPE	cat			Detected	Jensen- Shannon distance
>	DAYS_LAST_PHONE_CHANGE	num	أاست	السي	Detected	Wasserste distance (normed)
>	FLAG_EMAIL	num	1	1	Detected	Jensen- Shannon distance
>	FLAG_DOCUMENT_3	num	i l		Not Detected	Jensen- Shannon distance

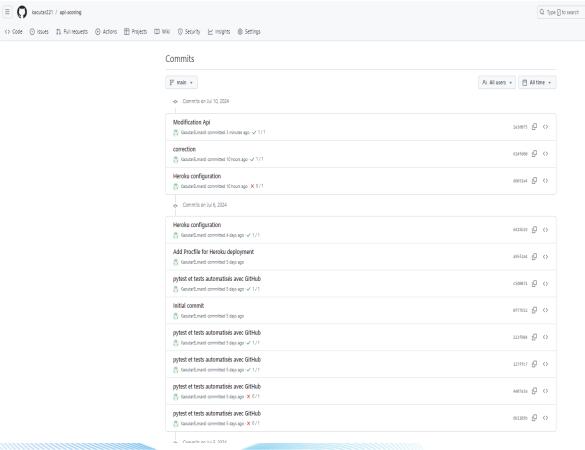
121 9 0.0744
Columns Drifted Columns Share of Drifted Columns

Data Drift Summary

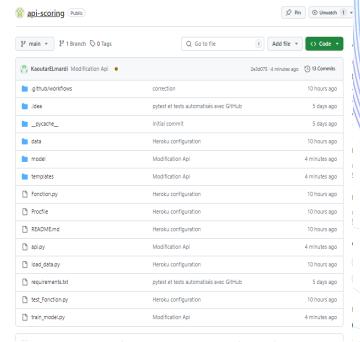




Processus de versionnement avec Git



Lien:https://github.com/kaoutar221/api-scoring.git



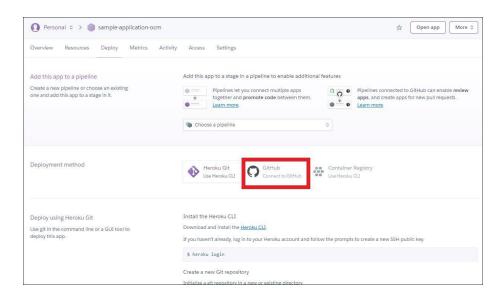
Présentation des Tests Unitaires

```
import pytest
import json
from Fonction import app
def test_homepage():
     with app.test_client() as client:
           response = client.get('/')
           assert response.data.decode('utf-8') == "Application, model, and data have been successfully loaded."
        ☐ kaoutar221 / api-scoring Public
        ⟨> Code ⊙ Issues ¹¹¹ Pull requests ⊙ Actions ☐ Projects ① Security ∠ Insights
                                                                                                                                               Python tests in test_Fonction.py
                                             All workflows
      Actions
                                                                                                                                          G G B □ ✓ Ø ≠ E Ø :
                                             Showing runs from all workflows
      All workflows
                                                                                                                                                                             6ms V Tests passed: 10 of 10 tests - 6ms
                                                                                                                                           Test Results
      test
                                               10 workflow runs
       Management
                                               Modification Api
                                                                                                                        main
      Caches
                                                 test #10: Commit 2e3d075 pushed by kaoutar221
      Deployments
                                               correction
       Attestations
                                                                                                                        main
                                                 test #9: Commit 614fd00 pushed by kaoutar221
                                                Heroku configuration
                                                 test #8: Commit d6031e4 pushed by kaoutar221

    Heroku configuration

                                                 test #7: Commit 6415b29 pushed by kaoutar221
                                               pytest et tests automatisés avec GitHub
                                                                                                                        main
                                                 test #6: Commit c5d0071 pushed by kaoutar221
```

Exécution du Déploiement de l'API





Lien:https://api-scoring-app-04b1217cf097.herokuapp.com/

Exemple de résultats



Conclusion

Thanks!

CREDITS: This presentation template was created by **Slidesgo**, and includes icons by **Flaticon**, and infographics & images by **Freepik**